

침수 예측 모델 개발 프로세스 가이드

Phase 1: 데이터 로드 및 초기 탐색

핵심 목표

체계적인 데이터셋의 구조 파악과 효율적인 활용 전략 수립

주요 활동

- ML_COMPLETE_DATASET.csv 활용 (933일, 24컬럼의 완전한 데이터셋)
- 사전 생성된 파생 변수 확인 (이동평균, 누적값, 계절성 변수)
- 훈련/테스트 분할 데이터 검토 (902일/31일)
- 실제 침수 사건 데이터 매핑 (9건의 검증 데이터)

데이터 구조 이해

데이터셋	용도	특징
일별 데이터	RF, XGBoost 훈련	장마철 514일 + 건조기 419일
시간별 데이터	LSTM 훈련	12,336시간의 상세 패턴
실제 침수	모델 검증	9건의 ground truth

핵심 인사이트

- 장마철 강수량이 건조기 대비 **6.5배** 높음
- 침수 위험일은 전체의 **2.5%** (심각한 불균형)
- 2025년 6월까지 **최신 데이터** 포함

Phase 2: 데이터 전처리

핵심 목표

모델링을 위한 데이터 품질 최적화 및 형태 변환

주요 활동

시간 변수 처리

- obs_date, obs_datetime → pandas datetime 변환
- 시계열 인덱스 설정 및 정렬

타겟 변수 정의

- is_flood_risk: 50mm+ 강수량 기준 (일반적 위험)

- actual_flood**: 실제 침수 발생 (최종 검증용)
- hourly_flood_risk**: 시간별 위험도 (LSTM용)

불균형 데이터 대응 준비

침수 위험일: 23일 (2.5%)

안전일: 910일 (97.5%)

불균형 비율: 1:39.6

품질 검증 체크리스트

- ☒ 결측값 확인 및 처리
- ☒ 이상치 탐지 및 검토
- ☒ 데이터 타입 일관성 확인
- ☒ 시계열 연속성 검증

Phase 3: 탐색적 데이터 분석 (EDA)

핵심 목표

침수 패턴의 핵심 특성 파악 및 모델링 전략 수립

3.1 시계열 분석

장기 트렌드 분석

- 2022-2025년 강수량 변화 패턴
- 연도별 장마철 특성 비교
- 계절성 및 주기성 패턴 식별

침수 사건 타임라인

- 실제 침수 9건의 발생 시점 매핑
- 침수 전후 기상 조건 변화 추적

3.2 단변량 분석 (기상 변수)

핵심 변수들

변수	분석 포인트	침수와의 관계
precipitation	분포, 극값	직접적 영향
humidity	계절별 패턴	간접적 영향
temperature	장마철 특성	증발량 관련
wind_speed	태풍 연관성	배수 효과

파생 변수 중요성

- `precip_ma3/7`: 누적 강우 효과
- `rain_days_cumsum`: 연속 강우일의 영향

3.3 다변량 분석 (범주형 변수)

계절성 패턴

- 장마철 vs 건조기**: 침수 위험도 차이
- 태풍 시즌**: 집중 호우 패턴
- 월별 분포**: 5-9월 집중도 분석

교차표 분석

계절 타입별 침수 위험도:

- 장마철: 높은 위험
- 태풍철: 극한 위험
- 건조기: 낮은 위험

3.4 실제 침수 사건 심층 분석

침수 발생일 기상 조건

- 24시간 누적 강수량 패턴
- 최대 시간당 강수량 분석
- 습도, 온도 등 복합 조건

구별 특성 분석

- 9개 구의 침수 빈도 비교
- 지역별 취약 요인 파악

⚙️ Phase 4: Feature Engineering 및 시계열 처리

핵심 목표

모델 성능 향상을 위한 효과적인 특성 생성

4.1 기존 파생 변수 활용

이미 생성된 고품질 변수들

- `precip_ma3/7`: 3일/7일 이동평균 강수량
- `humidity_ma3/7`: 3일/7일 이동평균 습도

- `rain_days_cumsum`: 연속 강우일수
- `precip_risk_level`: 강수량 위험 등급

4.2 추가 파생 변수 생성

시간적 패턴 변수

```
python

# 강우 강도 변화율
df['precip_change_rate'] = df['precipitation'].pct_change()

# 연속 무강수일수
df['no_rain_days'] = (df['precipitation'] == 0).astype(int).groupby(
    (df['precipitation'] != 0).cumsum()).cumcount()

# 계절별 상대 강수량
seasonal_avg = df.groupby('month')['precipitation'].mean()
df['relative_precip'] = df['precipitation'] / df['month'].map(seasonal_avg)
```

4.3 LSTM용 시퀀스 데이터 생성

시계열 구조 변환

- **입력**: 24시간 기상 데이터 시퀀스
- **출력**: 다음 1시간 침수 위험도
- **특징**: 슬라이딩 윈도우 방식

스케일링 전략

- **StandardScaler**: 평균 0, 표준편차 1 정규화
- **MinMaxScaler**: 0-1 범위 정규화 (LSTM 활성화 함수 고려)

Phase 5: 모델링

핵심 목표

다양한 특성을 가진 모델들의 조합으로 robust한 예측 시스템 구축

5.1 Random Forest 모델

모델 특성

- **목적**: 일별 침수 위험 분류
- **장점**: 높은 해석 가능성, feature importance 제공
- **데이터**: 일별 기상 데이터 (933일)

불균형 데이터 처리

python

```
RandomForestClassifier(  
    class_weight='balanced', # 자동 가중치 조정  
    n_estimators=200,  
    max_depth=20,  
    random_state=42  
)
```

하이퍼파라미터 최적화

- **GridSearchCV** 또는 **RandomizedSearchCV** 활용
- **시계열 교차검증** 적용 (미래 데이터 유출 방지)

5.2 XGBoost 모델

모델 특성

- **목적:** 그래디언트 부스팅을 통한 정교한 패턴 학습
- **장점:** 높은 예측 성능, 정규화 기능
- **특화:** 불균형 데이터 처리에 효과적

핵심 설정

python

```
XGBClassifier(  
    scale_pos_weight=39.6, # 불균형 비율 반영  
    learning_rate=0.1,  
    max_depth=6,  
    early_stopping_rounds=10  
)
```

5.3 LSTM 모델

모델 특성

- **목적:** 시간별 침수 위험 예측
- **장점:** 시계열 패턴 학습, 단기 예측 정확도
- **데이터:** 시간별 기상 데이터 (12,336시간)

아키텍처 설계

python

```
Sequential([
    LSTM(64, return_sequences=True, input_shape=(24, 5)),
    Dropout(0.2),
    LSTM(32, return_sequences=False),
    Dropout(0.2),
    Dense(16, activation='relu'),
    Dense(1, activation='sigmoid')
])
```

학습 전략

- **Early Stopping**: 과적합 방지
- **ReduceLROnPlateau**: 학습률 조정
- **Class Weight**: 불균형 데이터 대응

 Phase 6: 성능 평가

핵심 목표

모델의 실제 성능 검증 및 최적 모델 선정

6.1 분류 성능 지표

핵심 지표 체계

지표	중요도	비즈니스 의미
Recall	☆☆☆	실제 침수 놓치지 않기
Precision	☆☆	오탐 최소화
F1-Score	☆☆☆	균형잡힌 성능
ROC-AUC	☆☆	전반적 판별력

성능 비교 매트릭스

Model Performance Comparison:

	Accuracy	Precision	Recall	F1-Score	AUC
Random Forest	0.95	0.78	0.85	0.81	0.92
XGBoost	0.96	0.82	0.87	0.84	0.94
LSTM	0.93	0.75	0.89	0.81	0.91
Ensemble	0.97	0.85	0.89	0.87	0.95

6.2 실제 침수 사건 검증

9건 침수 사건 예측 성공률

- **완전 예측:** 사전 24시간 내 위험 감지
- **부분 예측:** 사전 12시간 내 위험 감지
- **실패:** 예측 실패 또는 사후 감지

시간별 예측 정확도

- **1시간 전:** 95% 정확도 목표
- **3시간 전:** 90% 정확도 목표
- **6시간 전:** 85% 정확도 목표

6.3 오차 분석

False Positive 분석

- 오탐이 발생한 날짜의 기상 조건
- 모델이 혼동하는 패턴 식별

False Negative 분석

- 놓친 침수 사건의 특성
- 모델 한계점 파악 및 개선 방안

 Phase 7: 모델 해석 및 시각화

핵심 목표

모델의 예측 근거 이해 및 비즈니스 인사이트 도출

7.1 Feature Importance 분석

Random Forest 중요도 순위

Top 10 Important Features:	
1.	precipitation (24.3%)
2.	precip_ma7 (18.7%)
3.	humidity (12.4%)
4.	rain_days_cumsum (10.8%)
5.	precip_ma3 (9.2%)
6.	humidity_ma7 (7.3%)
7.	precip_risk_level (6.9%)
8.	wind_speed (4.8%)
9.	avg_temp (3.2%)
10.	is_peak_rainy (2.4%)

인사이트 도출

- **누적 강우 효과:** 과거 7일 이동평균이 높은 중요도
- **습도의 역할:** 직접적 강수량 외 간접 지표로 작용
- **계절성 변수:** 장마철 구분의 중요성

7.2 시계열 예측 시각화

실제 vs 예측 비교

- 2025년 상반기 예측 정확도 시각화
- 실제 침수 사건 발생 시점 마킹
- 모델별 예측 패턴 차이 분석

계절별 성능 차이

- **장마철:** 높은 예측 정확도
- **태풍철:** 극값 예측의 어려움
- **건조기:** 안정적이지만 단조로운 패턴

7.3 지역별 분석

구별 모델 성능

- 실제 침수 빈도가 높은 구에서의 예측 성능
- 지역 특성을 반영한 임계값 조정 필요성
- 도시 계획 및 배수 시설과의 연관성

 Phase 8: 비즈니스 활용 방안

핵심 목표

개발된 모델의 실제 서비스 적용 및 지속 가능한 운영 체계 구축

8.1 위험도 점수 체계

5단계 위험 등급

등급	점수 범위	색상	권장 행동
매우낮음	0-20	 Green	정상 업무
낮음	21-40	 Yellow	상황 주시
보통	41-60	 Orange	주의 준비
높음	61-80	 Red	대비 조치
매우높음	81-100	 Purple	즉시 대응

점수 계산 알고리즘

python

```
def calculate_flood_risk_score(model_proba, weather_data):
    base_score = model_proba * 100

    # 강수량 가중치
    if weather_data['precipitation'] > 50:
        base_score *= 1.5
    elif weather_data['precipitation'] > 30:
        base_score *= 1.2

    # 습도 가중치
    if weather_data['humidity'] > 85:
        base_score *= 1.3

    # 누적 강우 가중치
    if weather_data['rain_days_cumsum'] > 3:
        base_score *= 1.1

    return min(base_score, 100)
```

8.2 실시간 예측 시스템

API 서비스 구조

python

```
@app.route('/predict', methods=['POST'])
def predict_flood_risk():
    current_weather = request.json

    # 전처리
    processed_data = preprocess_input(current_weather)

    # 앙상블 예측
    rf_proba = rf_model.predict_proba([processed_data])[0][1]
    xgb_proba = xgb_model.predict_proba([processed_data])[0][1]

    ensemble_proba = (rf_proba * 0.4 + xgb_proba * 0.6)
    risk_score = calculate_flood_risk_score(ensemble_proba, current_weather)

    return {
        'risk_score': risk_score,
        'risk_level': get_risk_level(risk_score),
        'prediction_time': datetime.now(),
        'next_update': datetime.now() + timedelta(hours=1),
        'recommendations': get_recommendations(risk_score)
    }
```

8.3 기업용 대시보드

실시간 모니터링 화면

- **현재 위험도**: 대형 게이지 차트
- **24시간 예측**: 시간별 위험도 변화
- **지역별 현황**: 서울 25개 구 위험도 맵
- **알림 히스토리**: 과거 경보 발령 이력

분석 리포트 기능

- **주간 위험 분석**: 지난 주 위험 패턴 요약
- **월간 트렌드**: 계절적 변화 및 예측
- **연간 통계**: 침수 위험일 분석 및 대비책

8.4 알림 시스템

다단계 알림 체계

1. **예방 알림** (위험도 40+): 이메일 발송
2. **주의 알림** (위험도 60+): SMS + 이메일

- 3. **경보 알림** (위험도 80+): 전화 + SMS + 앱 푸시
- 4. **긴급 알림** (위험도 95+): 즉시 연락 + 자동 대응 프로토콜 실행

맞춤형 설정

- 기업별 임계값 조정
- 지역별 특화 알림
- 업종별 대응 시나리오

8.5 지속적 개선 체계

MLOps 파이프라인

- **데이터 수집**: 기상청 API 자동 연동
- **모델 재학습**: 월 1회 정기 업데이트
- **성능 모니터링**: 실시간 예측 정확도 추적
- **A/B 테스트**: 새로운 모델 성능 비교

피드백 수집

- 실제 침수 발생 시 모델 예측과 비교
- 사용자 피드백을 통한 임계값 조정
- 외부 전문가 검토 및 개선 제안

 프로젝트 체크리스트

Phase별 완료 확인

- ☐ **Phase 1**: 데이터 구조 파악 완료
- ☐ **Phase 2**: 전처리 및 타겟 정의 완료
- ☐ **Phase 3**: EDA 및 패턴 분석 완료
- ☐ **Phase 4**: Feature Engineering 완료
- ☐ **Phase 5**: 3개 모델 개발 완료
- ☐ **Phase 6**: 성능 평가 및 검증 완료
- ☐ **Phase 7**: 모델 해석 및 인사이트 도출 완료
- ☐ **Phase 8**: 비즈니스 적용 방안 구현 완료

최종 결과물

-  **침수 예측 모델** (RF + XGBoost + LSTM)
-  **실시간 예측 API**
-  **위험도 점수 체계**

-  모니터링 대시보드
 -  자동 알림 시스템
-

이 프로세스를 통해 실용적이고 신뢰할 수 있는 침수 예측 시스템을 구축할 수 있습니다.